

# Avaliação da Estrutura de Saída de Redes Neurais Artificiais Utilizadas na Detecção de Faltas de Alta Impedância em Sistemas de Distribuição

Kelvin B. Nascimento  
Universidade Federal de Juiz de Fora  
Juiz de Fora, Brasil  
kelvin.bryan@engenharia.ufjf.br

Maria E. F. Octaviano  
Universidade Federal de Juiz de Fora  
Juiz de Fora, Brasil  
elisa.octaviano@engenharia.ufjf.br

Victor T. S. Rodrigues  
Universidade Federal de Juiz de Fora  
Juiz de Fora, Brasil  
victor.rodrigues@engenharia.ufjf.br

Débora R. R. P. Araujo  
Universidade Federal de Juiz de Fora  
Juiz de Fora, Brasil  
debora.rosana@ufjf.edu.br

Carla F. Cavallari  
Universidade Federal de Juiz de Fora  
Juiz de Fora, Brasil  
carla.cavallari@engenharia.ufjf.br

Leandro R. Araujo  
Universidade Federal de Juiz de Fora  
Juiz de Fora, Brasil  
leandro.araujo@ufjf.edu.br

**Abstract**—This paper proposes the usage of artificial neural networks for high impedance faults detection in power distribution systems, comparing neural networks with one and two neurons in the output layer. For testing, the 13 nodes and 34 nodes system from the IEEE are used. Load variations are used in simulations, which is common in real distribution systems and have a relevant impact on the fault detection process. In addition, the number of meters allocated is modified in simulations.

**Keywords**—high impedance faults, artificial neural networks, power distribution systems, fault detection.

## I. INTRODUÇÃO

Faltas de alta impedância (HIF – do inglês High Impedance Fault) em sistemas de distribuição (SD) de energia geralmente são causadas por condutores que entram em contato com superfícies de alta impedância, como árvores, asfalto, solos secos, etc. Por este motivo, uma HIF possui corrente de baixa magnitude, dificultando a detecção por parte dos dispositivos de sobrecorrente convencionais, pois estes não apresentam sensibilidade suficiente para distinguir tais correntes daquelas provenientes de variação de carga do sistema, por exemplo. Se uma falta de alta impedância não for detectada pelo sistema de proteção do SD, pode representar um perigo significativo para a população. Apesar de ser um evento comum em SD, a detecção de HIF ainda é um grande desafio para a proteção do sistema.

Muitos estudos foram desenvolvidos ao longo dos anos visando a detecção e a localização de HIFs. As redes neurais artificiais (RNAs) são bastante utilizadas para a detecção destas faltas em SD, sendo muitas vezes acopladas em outros métodos (Transformada de Wavelet e Lógica Fuzzy, por exemplo). Aproximadamente 23% das técnicas de detecção de HIFs utilizam topologias baseadas em redes neurais [5]. Um dos principais problemas é a definição da estrutura da RNA para tratar corretamente o problema de detecção de HIFs. Nesta definição encontram-se questões de números de neurônios, quantidade de camadas, estrutura de neurônios na saída, dentre outras.

A grande maioria dos trabalhos utiliza apenas uma camada oculta de neurônios. No entanto, alguns pesquisadores investigaram redes com maior número de

camadas. Em [3], o número de neurônios na saída é determinado a partir do método one of c-classes. E, no caso das camadas intermediárias, foi concluído que, para classificação da HIF, 4 neurônios na camada oculta é a melhor topologia, e que, para a localização da falta, 20 neurônios na primeira oculta e 15 na segunda compõem a configuração mais eficiente, para os testes realizados neste trabalho.

Em [8] verificou-se as potencialidades de RNAs multicamadas na caracterização de HIF monofásica. Utilizou-se RNAs com até 4 camadas intermediárias e bons resultados foram alcançados.

Em [4] foi utilizada uma RNA perceptron feed-forward back-propagation multicamadas para identificar três tipos de HIFs e foram analisadas redes com 1 e 4 neurônios na camada de saída. A saída com 4 neurônios apresentou erros maiores.

Em [2] comparou-se duas topologias de RNAs em sistemas com GD e utilizou a Transformada Wavelet Discreta (TWD) para tratar os sinais transitórios de corrente. Foram comparados os resultados de uma RNA com múltiplas saídas e três RNAs de saída única. A utilização de três RNAs apresentou melhor resultado.

Em [7] apresentou-se uma abordagem utilizando diferença de tensão para a detecção de HIFs e o método foi comparado com uma RNA com entradas do tipo TWD. A RNA possuía quatro saídas, cada uma delas correspondendo aos três tipos de faltas consideradas e às condições normais de operação. A precisão do algoritmo TWD-RNA foi 100% na gama de resistências de falta de 20-600  $\Omega$  em diferentes locais de falta.

Contudo diversos aspectos do sistema de distribuição como a variação da carga, desequilíbrios e indefinição da resistência de falta são negligenciados na maioria dos trabalhos. Alguns trabalhos recentes abordaram estes aspectos. Em [9] desenvolveu-se modelos e métodos numéricos, baseados em RNAs, para a detecção e a localização de áreas com defeitos de alta impedância em sistemas de distribuição. Neste trabalho foram considerados diversos aspectos dos sistemas de distribuição que são comumente ignorados como desequilíbrios, acoplamentos mútuos e variações de cargas. Em [1] utilizou-se um método baseado em algoritmos genéticos para alocação ótima de

medidores em SD e RNAs para a detecção e localização de faltas. As entradas das RNAs são grandezas elétricas de tensão e corrente, podendo ser medições fasoriais e/ou não-fasoriais. A arquitetura da RNA utilizada foi com apenas um neurônio na camada de saída.

Ambos os trabalhos, [9] e [1], consideraram diversos aspectos dos SD, porém, analisaram RNAs com apenas um neurônio na camada de saída.

O objetivo do presente trabalho é analisar estruturas de saídas diferentes para as RNAs, comparando a utilização de um neurônio com a de dois neurônios na camada de saída. Nas simulações serão consideradas variações de carga nos sistemas de forma a tornar os resultados mais reais. E ainda, é possível analisar o impacto da variação do número de medidores nos resultados obtidos.

## II. PREMISSAS BÁSICAS

### A. Faltas de Alta Impedância

Conforme apresentado na seção I, as HIFs se configuram como um grande problema para o SD, principalmente devido à baixa amplitude da corrente gerada pela falta. A Tabela I fornece as magnitudes de corrente observadas em um teste de HIF considerando o contato do cabo com grama, areia e asfalto, secos e úmidos [11].

TABELA I – MAGNITUDE DE CORRENTES DE HIF OBSERVADAS EM TESTES COM ALGUMAS SUPERFÍCIES DE CONTATO [11].

Superfície de contato	Corrente (A)
Grama seca	< 60
Grama molhada	< 90
Asfalto molhado	< 20
Areia seca	< 10
Areia molhada	< 50

### B. Redes Neurais Artificiais

As redes neurais artificiais foram desenvolvidas com base no funcionamento de uma rede neural biológica. O neurônio é a unidade básica de processamento de uma rede neural e conforme representado na Fig. 1, possui sinais de entrada  $x_i$ , pesos sinápticos, uma função de ativação e um bias  $b_k$ , que tem o efeito de aumentar ou diminuir a entrada da função de ativação.




Fig. 1 – Modelo de um neurônio artificial [6].

Os sinais recebidos pelas entradas são multiplicados pelos seus respectivos pesos sinápticos e são somados ponderadamente produzindo um nível de atividade. Se esse nível exceder certo valor, a saída  $y_k$  é ativada de acordo com a função de ativação [10].

## III. IMPACTO DA TOPOLOGIA DA CAMADA DE SAÍDA NA DETECÇÃO DE DEFEITOS

### A. Definição do problema

Conforme citado na Introdução, um dos problemas na detecção de faltas de alta impedância utilizando RNAs é a determinação da quantidade de neurônios na camada de saída.

Alguns autores indicam a utilização de apenas um neurônio na camada de saída com valores variando entre zero e um para indicar a existência ou não de defeitos. Neste caso, os valores de saída são arredondados para o valor inteiro mais próximo. Um dos problemas apontados é que estes arredondamentos, principalmente dos valores em torno de 0,5, podem levar a resultados errados.

Outros autores recomendam utilizar um maior número de neurônios na camada da saída para tentar evitar erros de aproximações e aumentar a robustez do método. Um tipo usual é a saída com dois neurônios, onde é feita uma comparação simples: se o valor do primeiro neurônio for maior que o segundo, não existe falta e vice versa. De forma semelhante, ressalta-se que este tipo de construção também pode apresentar problemas de separação de padrões, devido a proximidade de valores, especialmente quando os resultados de ambos os neurônios são semelhantes.

Sendo assim, o objetivo principal deste trabalho consiste em verificar se há uma vantagem significativa na utilização de apenas um ou de dois neurônios na camada de saída das RNAs utilizadas para detecção de HIFs em sistemas de distribuição, considerando-se a variação do carregamento do sistema concomitante ao evento da falta.

### B. Método proposto

Para o desenvolvimento deste trabalho foram criados bancos de dados compostos pelas correntes nas linhas do sistema em coordenadas de sequência obtidas em função de determinadas condições de defeitos. Os fatores que definem determinada condição de defeito são: a existência ou não do defeito, a localização e o valor da resistência de falta. Estas condições são sorteadas aleatoriamente em cada simulação.

As correntes em coordenadas de sequência são obtidas a partir de uma transformação simples das correntes em coordenadas de fase em regime permanente e no domínio da frequência, utilizando o teorema de Fortescue.

Para retratar com mais fidelidade os SD, foi considerada a variação de carga nos sistemas. Para tanto, em cada simulação, cada carga é multiplicada por um valor aleatório entre 0,85 e 1,15. Esta consideração faz com que os dados fiquem mais próximos de situações reais, mas, torna-se um complicador a mais para as RNAs, pois a variação de corrente oriunda das variações das cargas pode encontrar-se na mesma ordem de grandeza da variação da corrente devido aos defeitos de alta impedância. Dessa forma, ressalta-se que as variações das cargas e as faltas são simultaneamente aplicadas em cada simulação, de forma a tornar o problema

mais realístico. As resistências de falta foram consideradas entre 100 e 200 ohms.

Após a criação dos bancos de dados partiu-se para o desenvolvimento das RNAs. As redes utilizadas neste trabalho possuem uma camada de entrada, uma camada intermediária (ou oculta) e uma camada de saída.

A camada de entrada possui o número de neurônios equivalente a quantidade de medidores alocados em cada caso simulado, cujas informações de módulo de corrente em coordenadas de sequência estão armazenados no banco de dados e servem como os dados de entrada para a detecção da falta. Já o número de neurônios da camada oculta foi obtido empiricamente em cada caso, buscando-se a otimização do desempenho das redes. E como o objetivo deste trabalho consiste na comparação entre as redes neurais com um e dois neurônios na camada de saída foram construídas redes neurais com estas duas estruturas de saída.

As simulações realizadas neste trabalho foram desenvolvidas pelo software Matlab versão R2016a.

### C. Redes neurais com um neurônio na camada de saída

Esta topologia de rede neural com apenas um neurônio de saída apresenta valores 0 ou 1 para ausência ou presença de algum curto-circuito, respectivamente. Dessa forma, durante a fase de treinamento, os ajustes internos da RNA são trabalhados para fornecer um único valor de saída (normalmente próximos de 0 ou 1). Porém, conforme já comentado anteriormente, o problema desta construção é que em alguns casos são obtidos valores próximos a 0,5 por exemplo, mostrando indecisão da RNA para classificar estes casos.

A Fig. 2 ilustra a topologia de uma RNA genérica com apenas um neurônio na camada de saída.




Fig. 2– Representação de uma RNA com apenas um neurônio na camada de saída.

### D. Redes Neurais com dois neurônios na camada de saída

Esta topologia de rede neural é estruturada de modo a apresentar nos neurônios da última camada a saída 0-1, em casos com curto-circuito, e, a saída 1-0, em casos sem curto-circuito. Dessa forma, pretende-se eliminar as indecisões das RNAs explicitado na seção anterior, porque, durante o treinamento, a rede se ajustará para fornecer duas saídas antagônicas para casos com ou sem curto-circuito. A Fig. 3 ilustra a topologia de uma RNA genérica com dois neurônios na camada de saída.




Fig. 3 - Representação de uma RNA com dois neurônios na camada de saída.

### E. Métricas de comparação utilizadas

As redes neurais propostas neste trabalho necessitam ser eficazes tanto para detecção de casos em que há falta no sistema quanto para casos em que não há falta.

Desta forma, (1) e (2) são utilizadas, respectivamente, para os cálculos das eficiências das redes na detecção de casos com falta e sem faltas perturbando o sistema.

$$E_{CC}(\%) = \left( \frac{VP}{NCC} \right) \times 100 \quad (1)$$

$$E_{NCC}(\%) = \left( \frac{VN}{NPO - NCC} \right) \times 100 \quad (2)$$

Onde:

$E_{CC}$  é a eficiência de determinada RNA na detecção dos casos com falta.

$E_{NCC}$  é a eficiência de determinada RNA na detecção dos casos sem falta.

$VP$  é o número de acertos da RNA para casos em que havia curto-circuito aplicado no sistema.

$VN$  é o número de acertos da RNA para casos em que não havia curto-circuito aplicado no sistema.

$NCC$  é o número total de casos em que havia curto-circuito aplicado no sistema.

$NPO$  é o número total de casos armazenados no banco de dados.

A Equação (3) é utilizada para cálculo da eficiência total da rede, isto é, a eficiência para detectar os casos com e sem falta juntos.

$$E_T(\%) = \left( \frac{E_{CC}(\%) + E_{NCC}(\%)}{2} \right) \quad (3)$$

Onde:  $E_T$  é a eficiência total de determinada RNA.

Como pode ser observado em (3), o mesmo peso é dado para acertos em casos com presença e em casos com ausência de faltas, reforçando a ideia de que a rede deve ser efetiva para indicar ambos os casos.

#### IV. RESULTADOS

Neste trabalho, os sistemas de distribuição IEEE 13 barras e IEEE 34 barras foram utilizados para testar o método proposto e realizar comparações

Para cada sistema foi criado um banco de dados contendo 2000 pontos operativos diferentes, onde todos os valores de corrente obtidos pelos medidores foram armazenados. Cada banco de dados é composto por aproximadamente 75% dos casos contendo curto-circuito, com local do defeito, resistência de defeito e carregamento sorteados de forma aleatória e cerca de 25% dos casos são livres de faltas e com carregamento aleatório.

Após a criação do banco de dados, as RNAs propostas (seção 3.3 e 3.4) foram treinadas e validadas para detecção de faltas em sistemas de distribuição. A partir dos testes pode-se verificar qual rede apresenta o melhor desempenho na detecção: com um neurônio ou com dois neurônios na camada de saída.

##### A. Testes com o sistema IEEE 13 barras

A Fig. 4 ilustra a topologia do sistema IEEE 13 barras. Neste sistema foram realizadas três simulações: com um, dois e três medidores. Os resultados obtidos para cada simulação foram apresentados separadamente nas próximas subseções, seguidos por uma breve análise dos resultados alcançados.




Fig. 4 – Diagrama esquemático do Sistema IEEE 13 barras.

##### 1) Sistema IEEE 13 barras com um medidor

Nesta simulação o único medidor foi alocado na linha entre as barras 650 e 632. Os resultados obtidos pelas RNAs com um e dois neurônios na camada de saída são mostrados na Tabela II.

TABELA II – PARÂMETROS DAS RNAs NO SISTEMA IEEE 13 BARRAS COM UM MEDIDOR.

Número de neurônios na camada de saída	NPO	NCC	VP	VN
1 neurônio	2000	1451	1219	399
2 neurônios	2000	1451	1224	389

A primeira coluna da Tabela II diferencia os tipos de estruturas de saída das RNAs. A segunda coluna (NPO) mostra o número total de casos no banco de dados. A terceira coluna (NCC) mostra o número de casos com curto-circuito no banco de dados. A quarta (VP) e a quinta coluna (VN) mostram os valores obtidos, durante o treinamento, para os parâmetros VP e VN, respectivamente. Estes valores, conforme já mencionado, são utilizados nos cálculos das eficiências das redes neurais.

Utilizando (1) e (2) e (3), é possível calcular os valores das eficiências das redes. Os resultados podem ser visualizados através do gráfico na Fig. 5.




Fig. 5– Gráfico dos desempenhos das RNAs para o sistema IEEE 13 barras com um medidor.

##### 2) Sistema IEEE 13 barras com dois medidores

Nesta simulação os medidores foram alocados nas linhas entre as barras 650 e 632, e entre as barras 671 e 692. Os resultados obtidos das RNAs são mostrados na Tabela III e na Fig. 6.

TABELA III – PARÂMETROS DAS RNAs NO SISTEMA IEEE 13 BARRAS COM DOIS MEDIDORES.

Número de neurônios na camada de saída	NPO	NCC	VP	VN
1 neurônio	2000	1462	1289	471
2 neurônios	2000	1462	1281	468




Fig. 6- Gráfico dos desempenhos das RNAs para o sistema IEEE 13 barras com dois medidores.

### 3) Sistema IEEE 13 barras com três medidores

Nesta simulação os medidores foram alocados nas linhas entre as barras 650 e 632, 671 e 692 e 632 e 671. Os resultados obtidos das RNAs são mostrados na Tabela IV e na Fig. 7.

TABELA IV – PARÂMETROS DAS RNAs NO SISTEMA IEEE 13 BARRAS COM TRÊS MEDIDORES.

Número de neurônios na camada de saída	NPO	NCC	VP	VN
1 neurônio	2000	1464	1346	493
2 neurônios	2000	1464	1341	493




Fig. 7- Gráfico dos desempenhos das RNAs para o sistema IEEE 13 barras com três medidores.

### 4) Análise dos resultados

Analisando-se os resultados obtidos pelas simulações desta seção, nota-se que a maioria das RNAs foram mais eficientes para a detecção de casos com falta e a RNA com um neurônio na camada de saída foi, no geral, um pouco mais eficiente que a RNA com dois neurônios. Ressalta-se que como são considerados diversos aspectos dos SD, como a variação do carregamento, os valores totais de eficiência não são tão bons como trabalhos que não a consideram. Porém, a variação de carga existe e deve ser considerada na busca por resultados mais realistas.

Nota-se também que independentemente do número de neurônios na camada de saída a eficiência total da rede aumentou com o número de pontos de medição.

### B. Testes com o sistema IEEE 34 barras

A Fig. 8 ilustra a topologia do sistema IEEE 34 barras.




Fig. 8 – Diagrama esquemático do Sistema IEEE 34 barras.

Assim como na seção anterior, foram realizadas três simulações variando-se o número de medidores alocados no sistema em: dois, três e quatro. Os resultados obtidos para cada simulação foram apresentados separadamente nas próximas subseções.

#### 1) Sistema IEEE 34 barras com dois medidores

Nesta simulação os medidores foram alocados nas linhas entre as barras 800 e 802 e entre as barras 854 e 852. Os resultados obtidos pelas RNAs são mostrados na Tabela V e na Fig. 9.

TABELA V – PARÂMETROS DAS RNAs NO SISTEMA IEEE 34 BARRAS COM DOIS MEDIDORES.

Número de neurônios na camada de saída	NPO	NCC	VP	VN
1 neurônio	2000	1495	1361	498
2 neurônios	2000	1495	1355	495

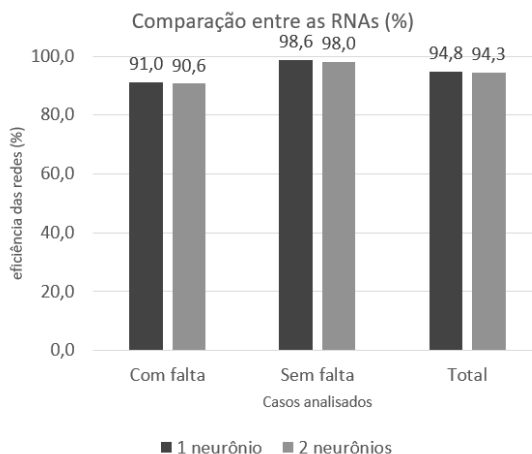


Fig. 9- Gráfico dos desempenhos das RNAs para o sistema IEEE 34 barras com dois medidores.

#### 2) Sistema IEEE 34 barras com três medidores

Nesta simulação os medidores foram alocados nas linhas entre as barras 800 e 802, 816 e 824 e 858 e 834. Os resultados obtidos das RNAs são mostrados na Tabela VI e pela Fig. 10. Nota-se que a eficiência total da rede com dois neurônios foi superior neste caso.

TABELA VI – PARÂMETROS DAS RNAs NO SISTEMA IEEE 34 BARRAS COM TRÊS MEDIDORES.

Número de neurônios na camada de saída	NPO	NCC	VP	VN
1 neurônio	2000	1511	1414	466
2 neurônios	2000	1511	1440	482

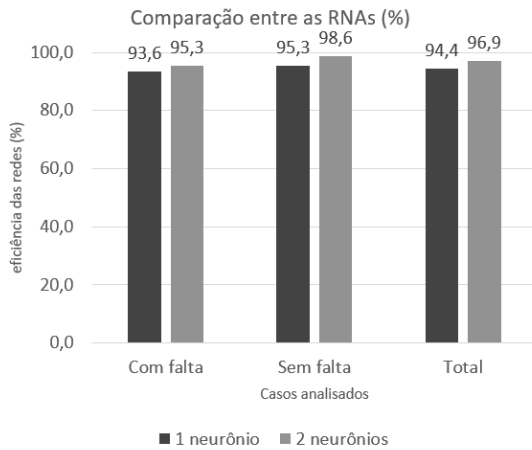


Fig. 10- Gr fico dos desempenhos das RNAs para o sistema IEEE 34 barras com tr s medidores.

### 3) Sistema IEEE 34 barras com quatro medidores

Nesta simula  o os medidores foram alocados nas linhas entre as barras 800 e 802, 816 e 824, 854 e 852 e 858 e 834. Os resultados obtidos pelas RNAs com um e dois neur nios na camada de sa da s o mostrados na Tabela VII e Fig.11.

TABELA VII – PAR METROS DAS RNAs NO SISTEMA IEEE 34 BARRAS COM QUATRO MEDIDORES.

N�mero de neur�nios na camada de sa�da	NPO	NCC	VP	VN
1 neur�nio	2000	1467	1383	524
2 neur�nios	2000	1467	1350	514




Fig. 11- Gr fico dos desempenhos das RNAs para o sistema IEEE 34 barras com quatro medidores.

## V. CONCLUS O

A partir da an lise dos resultados obtidos pelas simula  es nota-se que ambas as RNAs foram eficientes para a detec  o de casos com falta de alta imped ncia. Al m disso,   importante destacar que o m todo proposto pode ainda apresentar certas indecis es quanto a exist ncia ou n o de falta no sistema. Recomenda-se ent o, que as provid ncias tomadas em casos com faltas sejam tamb m aplicadas nos casos duvidosos, a fim de se evitar maiores problemas na rede.

Ressalta-se que utiliza  o de varia  o do carregamento impacta nos resultados tornando mais dif cil a detec  o de defeitos.

Com rela  o ao n mero de neur nios na camada de sa da, n o se pode inferir alguma superioridade de determinada estrutura de sa da de RNA, logo se considera que as duas abordagens podem ser utilizadas. Notou-se, conforme esperado, que a utiliza  o de mais medidores impacta de forma positiva nos resultados.

## AGRADECIMENTOS

Os autores gostariam de agradecer a CNPq, CAPES, FAPEMIG, PPEE/UFJF e ao INERGE.

## REFER NCIAS BIBLIOGR FICAS

- [1] Ac cio, L. C. (2017). Aloca  o  tima de medidores para fins de detec  o de falhas. Mestre. Universidade Federal de Juiz de Fora.
- [2] ElNozahy, M.S., EL-Shatshata, R.A. and Salamaa, M.M.A. (2016). Single-phasing detection and classification in distribution systems with a high penetration of distributed generation. Electric Power Systems Research, 131, pp. 41–48.
- [3] Fanucchi, R. Z. (2014). A Detec  o e Localiza  o de Faltas de Alta Imped ncia em Sistemas de Distribui  o Utilizando Transformadas Wavelets e Redes Neurais Artificiais. Mestre. Universidade de S o Paulo.
- [4] Garc a, J., Garc a, V. and Kagan, N. (2014). Detection of high impedance faults in overhead multi grounded networks. In: 11 th IEEE/IAS International Conference on Industry Applications. IEEE pp. 1-6.
- [5] Ghaderia, A., Ginn III, H. L. and Mohammadpourb, H. A. (2017). High impedance fault detection: A review. Electric Power Systems Research, 143, pp. 376–388.
- [6] Haykin, S. (2001). Redes neurais: princ pios e pr tica. Bookman, 2.ed. Porto Alegre – RS.
- [7] Hubana, T., Saric, M. and Avdakovi , S. (2017). Approach for identification and classification of HIFs in medium voltage distribution networks. IET Gener. Transm. Distrib., 12, issue 5, pp. 1145-1152.
- [8] Kotlinski, E. (2013). Detec  o de falta de alta imped ncia em sistema de distribui  o radial utilizando redes neurais artificiais. Mestre. Universidade Regional do Noroeste do Estado do Rio Grande do Sul.
- [9] Ledesma, J. J. G. (2017). Metodologia para detec  o e localiza  o de  reas de defeitos de alta imped ncia com a presen a da gera  o distribu da. Doutor. Universidade Federal de Juiz de Fora.
- [10] Moreto, M. (2005). Localiza  o de faltas de alta imped ncia em sistemas de distribui  o de energia: uma metodologia baseada em redes neurais artificiais. Mestre. Universidade Federal do Rio Grande do Sul.
- [11] Santos, W. C., Souza, B. A., Brito, N. S. D., Costa, F. B. and Paes Jr, M. R. C. (2013). High Impedance Faults: From Field Tests to Modeling. J Control Autom Electr Syst, 24, pp. 885–896.
- [12] Santos, W. C., Lopes, F. V., Brito, N. S. D and Souza, B. A. (2017). High-Impedance Fault Identification on Distribution Networks. IEEE Transactions On Power Delivery, 32, pp. 23-3.